Izveštaj

1. Izvršiti kontrolu kvaliteta FASTQ fajlova alatom FastQC. Priložiti izvrštaj i diskutovati rezultate (da li je neki od kriterijuma koje analizira FastQC označen kao problematičan, i šta taj kriterijum znači?)

   Per base sequence content

   Grafik sa proporcijama svake baze u nasem genomu. Ono što očekujemo je da nema mnogo razlike između učestalosti baza (svaka oko 25%) i da su linije paralelne.

   WARN - fastQC izdaje upozorenje ako je razlika između A i T ili G i C veća od 10% na bilo kojoj poziciji.

   FAIL - ako je razlika između A i T ili G i C veća od 20% na bilo kojoj poziciji.

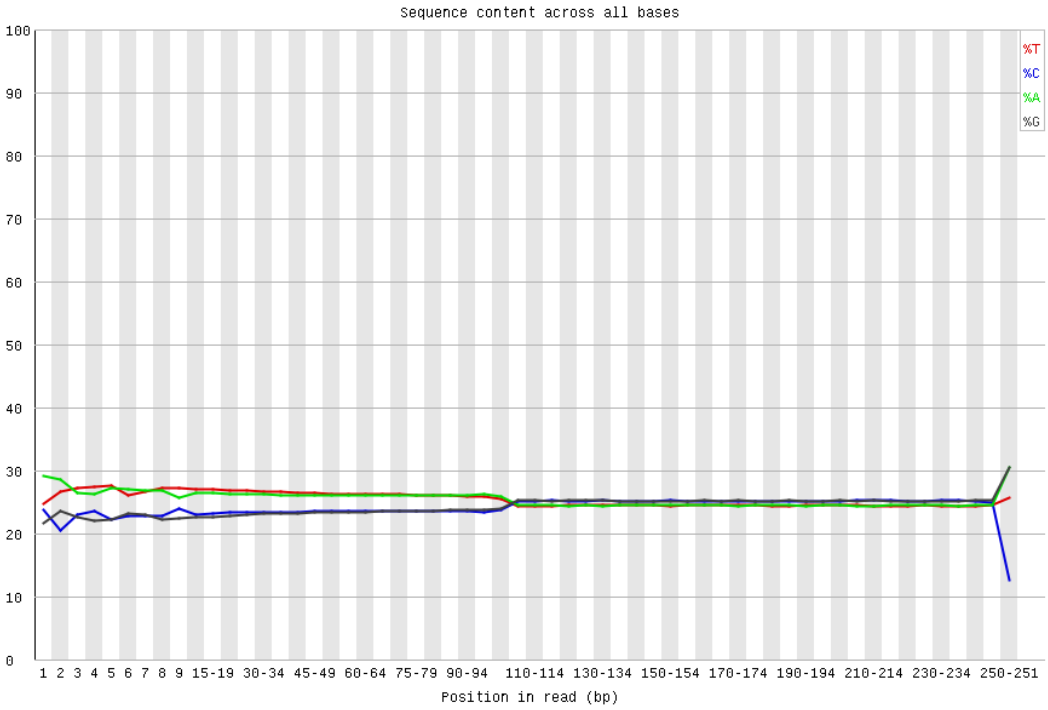

   Per sequence GC content

   GC sadržaj se meri kroz celu sekvencu i upoređuje sa modelom normalne raspodele GC sadržaja. Očekujemo distribuciju približnu normalnoj. Distribucije neobičnog oblika mogu da indikuju kontaminaciju sadržaja.

   WARN - ako je suma devijacija od modela normalne raspodele veća od 15% svih read-ova

   FAIL - ako je suma devijacija od modela normalne raspodele veća od 30% svih read-ova

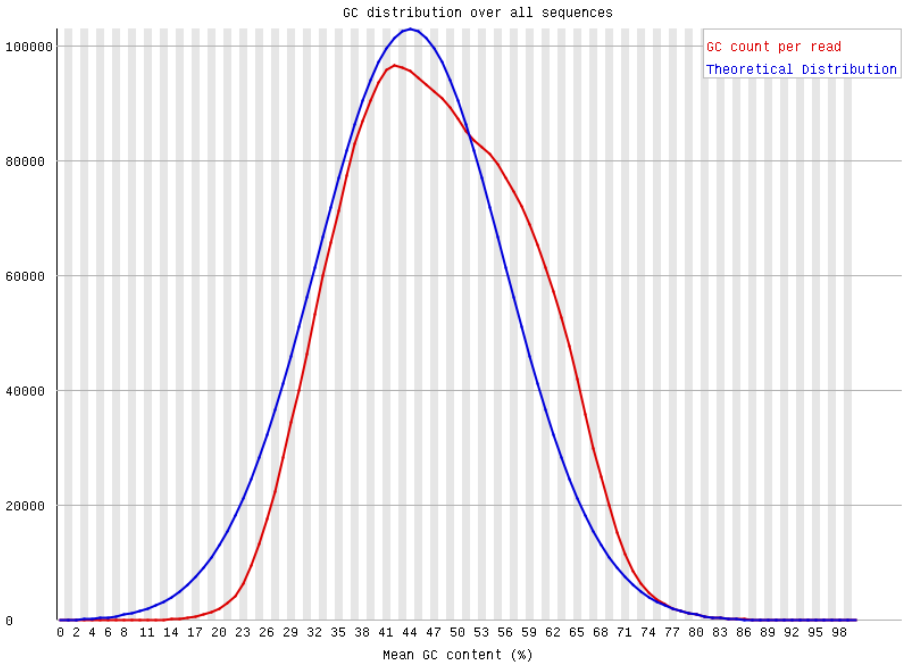

Sequence Length Distribution

Grafik koji prikazuje distribuciju dužina fragmenata unutar analiziranog fajla. Čak i kod biblioteka sa uniformnim dužinama neke sekvence budu skraćene kako bi se odstranile baze niskog kvaliteta.

WARN - ako sve sekvence nisu iste dužine

FAIL - ako postoje sekvence dužine 0

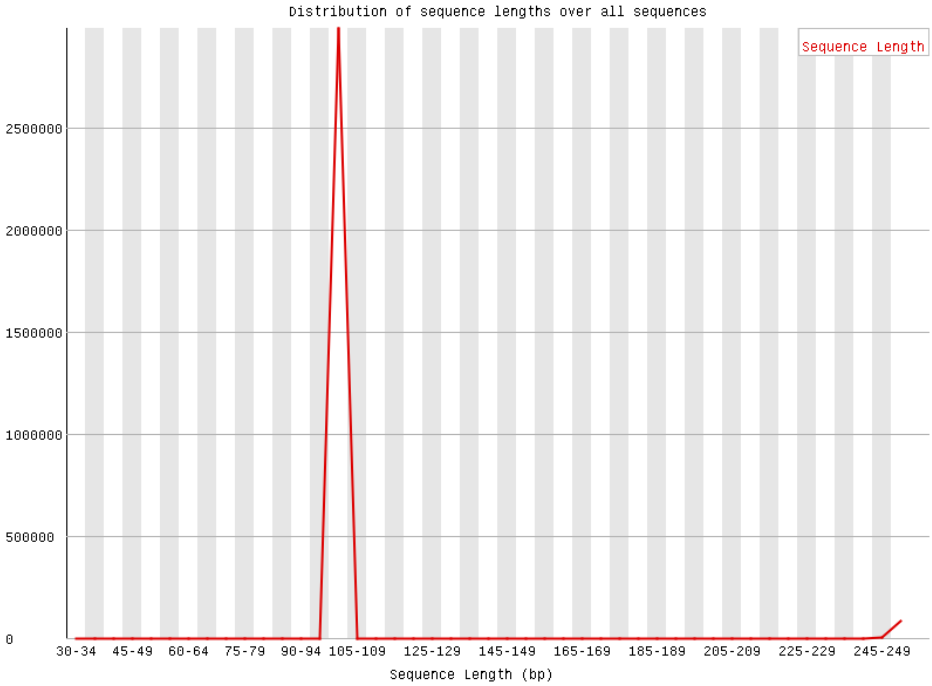

2. Mapirati sekvencirane readove na referentni genom hg38 upotrebom alata BWA Mem. Upotrebom python biblioteke pysam odrediti sledeće:

   a. Koliko je readova uspešno mapirano?

      Od ukupno 6.001.858 readova, uspešno je mapirano 5.985.566

   b. Koliko je parova readova mapirano tako da su oba para mapirana?

      Uspešno je mapirano 2.983.863 parova

   c. Nacrtati histogram dužina sekvenciranih fragmenata (template_length).

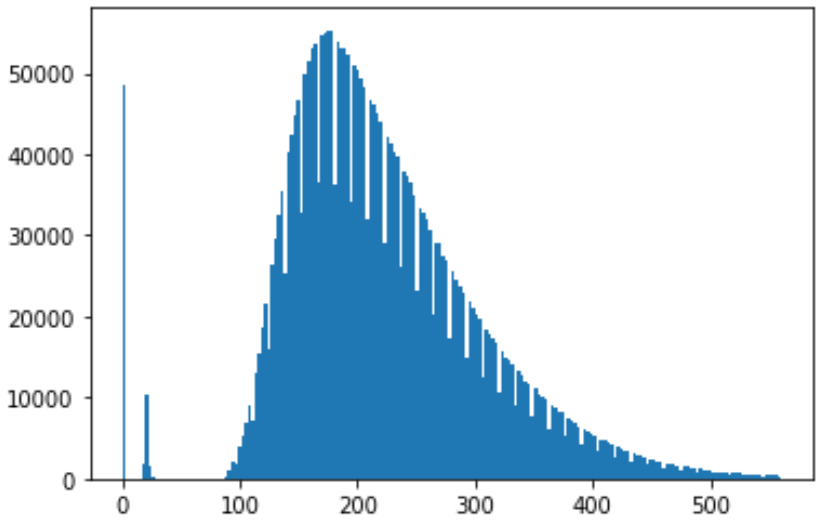

X osa predstavlja dužinu sekvenciranih fragmenata, a Y osa broj fragmenata određene dužine. Dužina je setovana na 0 ukoliko informacije nisu dostupne ili ukoliko je u pitanju single-segment fragment (template).

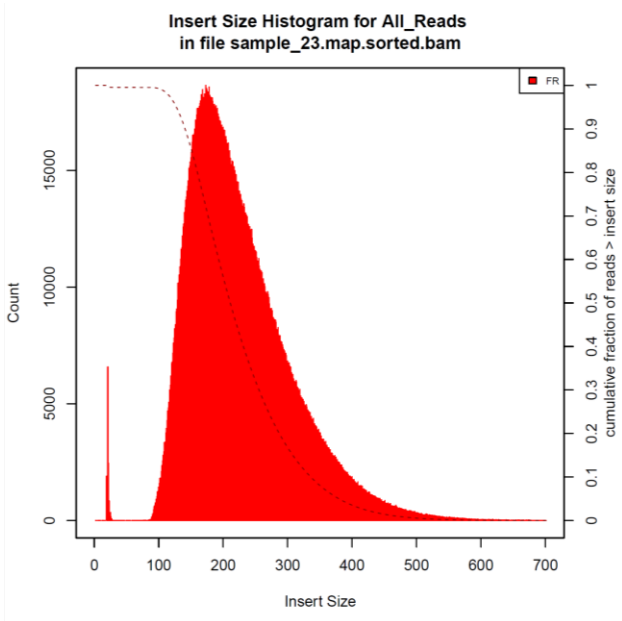

3. Izvršiti obradu dobijenog BAM fajla prema GATK protokolu (Markiranje Duplikata, rekalibracija kvaliteta baza)
    a. Koliki su procenati PCR i optičkih duplikata?

        Ukupno postoji 939.342 duplikata, od kojih je 0 optičkih, što znači da su ostali PCR.

        Procenat optičkih duplikata: 0%

        Procenat PCR duplikata: (939.342 * 100) / 6.001.858 = 15.65%

        PCR duplikati – nastali tokom pripreme podataka PCR metodom

        Optički duplikati – greške sekvencera

4. Identifikovati mutacije upotrebom alata Haplotype Caller i filtirtati mutacije predefinisanim filterima (hard filtering) prema Broad preporukama (kao što je rađeno na vežbama).
    a. Koliko je ukupno mutacija identifikovano, koliko od njih su SNP-ovi, a koliko INDEL-i?

        Ukupno je identifikovano 12059 mutacija, od kojih su 10702 SNP-ovi i 1357 INDEL-i.

    b. Koliko mutacija prolazi, a koliko ne prolazi kriterijume filtriranja.

        Ukupno 287 mutacija ne prolazi kriterijume filtriranja. Od toga su 216 SNP-ovi i 71 INDEL-i. Filtriranje je prošlo ukupno 11.772 mutacija.

    c. Izračunati Ti/Tv odnos pre i posle filtriranja.

        Pre filtriranja: 2.0121024486349564

        Posle filtririanja: 2.0158227848101267

        Očekivani Ti/Tv odnos je blizu 3.

5. Anotirati mutacije alatom Funcotator
    a. Izbrojati različite vrednosti ClinVar značajnosti (anotacija ClinVar_VCF_CLNSIG, koliko mutacija je označeno kao Benign, Likely_benign, itd.)

        Benign : 248

        Benign/likely benign : 55

        Uncertain significance : 5

        Likely benign : 25

        Not provided : 11

        Benign/likely benign drug response risk factor : 1

        Pathogenic : 1

Conflicting interpretations of pathogenicity affects : 1

Conflicting interpretations of pathogenicity : 2

Association : 1

Risk factor : 2

Drug response : 2

Protective : 1

6. Svi uzorici sadrže određenu količinu kontaminacije DNK materijalom bakterijskog ili virusnog porekla. Većina ovakvih readova se neće mapirati na ljudski genom. Izvući readove koji nisu mapirani u procesu mapiranja, asemblovati ih alatom abyss, i identifikovati organizam od kojeg potiče najduži skafold upotrebom alata Blast.

   Najduži skafold potiče od bakterije Escherichia Coli.

   https://www.ncbi.nlm.nih.gov/Taxonomy/Browser/wwwtax.cgi?id=1055537

   https://en.wikipedia.org/wiki/Escherichia_coli